Laboratorio di Reti e Sistemi Distribuiti

11: Linking ed ELF file

Roberto Marino, PhD[1]
roberto.marino@unime.it

[1]Dipartimento di Matematica, Informatica, Fisica e Scienze della Terra
Future Computing Research Laboratory
Università di Messina

Last Update: 27th March 2025

Compiler Driver

Abbiamo visto durante la lezione precedente che gcc (compiler driver) è il programma front-end che gestisce l'intero processo di compilazione in un compilatore come gcc (GNU Compiler Collection). **gcc** non è quindi solo il compilatore vero e proprio, ma un driver che coordina diverse fasi del processo di compilazione

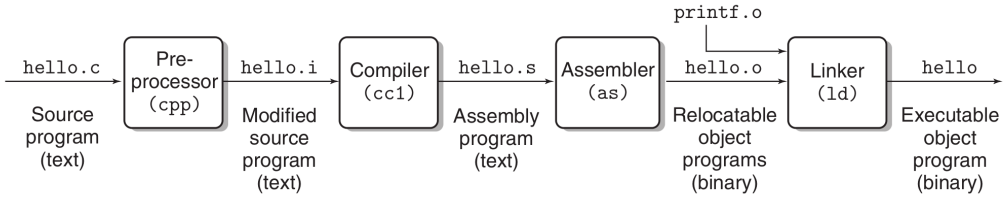

Esplicitare le fasi di compilazione

Se vogliamo invocare manualmente le varie fasi (compilazione granulare):

```
gcc -E main.c -o main.i   # Solo preprocessing (chiama cpp)
gcc -S main.i -o main.s   # Solo compilazione in assembly (chiama cc1)
gcc -c main.s -o main.o   # Solo assemblaggio (chiama as)
gcc main.o sum.o -o prog  # Solo linking (chiama ld)
```

Linking Statico

Definizione

Il linking statico è un processo in cui tutte le librerie necessarie per un programma vengono copiate direttamente nell'eseguibile finale, rendendolo **indipendente da librerie esterne** al momento dell'esecuzione.

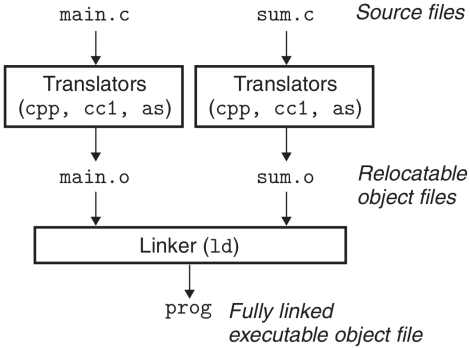

Linking Statico e Dinamico

Durante il linking statico il linker `ld` combina:

- File oggetto (.o) generati dal compilatore.
- Librerie statiche (.a), che contengono il codice precompilato di funzioni necessarie.
- Simboli e riferimenti per generare l'eseguibile finale.

Differenza principale dal linking dinamico:

- Statico: Il codice delle librerie è incluso direttamente nell'eseguibile.
- Dinamico: Il programma fa riferimento a librerie esterne condivise (.so) al momento dell'esecuzione.

```
1 gcc -static main.o -o prog -L/usr/lib -lmylib # (con libmylib.a)
2 gcc -o prog main.c -L/usr/lib -lmylib # (dinamico, con libmylib.so)
```

Si può usare il comando `ldd` per verificare se un programma è linkato staticamente o dinamicamente

Remark: Definizione vs Dichiarazione vs Inizializzazione

Definizione

La definizione è il momento in cui una variabile o una funzione viene "creata", ovvero viene allocato **lo spazio in memoria per essa**. Una definizione può includere un'inizializzazione, ma non è obbligatoria.

Inizializzazione

Una inizializzazione è l'atto di **assegnare un valore iniziale** ad una variabile al momento della sua definizione.

Dichiarazione

Una dichiarazione **informa il compilatore dell'esistenza e del tipo di una variabile o funzione**, ma non necessariamente ne crea l'allocazione.

Esempi

La variabile è **dichiarata**, ma è **definita** (spazio allocato) in un altro file oggetto:

Dichiarazione di una variabile senza definizione

```
extern int a;
```

La funzione è dichiarata ma la sua implementazione non ancora (altrove nello stesso file oggetto o in un altro file:

Dichiarazione di una funzione senza definizione

```
int funzione(int x);
```

Remark: variabili static

Le variabili `static` vengono allocate una sola volta e rimangono in memoria per l'intera esecuzione del programma. Ciò significa che il loro valore persiste tra le chiamate alla funzione in cui sono dichiarate o tra le varie parti del programma se dichiarate a livello globale.

a livello di funzione

Sono visibili (scope) solo all'interno della funzione in cui sono definite

a livello di file oggetto

Sono visibili (scope) solo all'interno del file oggetto, non sono risolubili esternamente

Cosa fa nel dettaglio il linker?

I **linker statici**, come il programma `ld` di Linux, prendono in ingresso un insieme di file oggetto rilocabili e di argomenti della riga di comando e generano in uscita un file oggetto eseguibile completamente risolto che può essere caricato ed eseguito. I file oggetto rilocabili in ingresso consistono in varie sezioni di codice e dati, dove ogni sezione è una sequenza contigua di byte. Le **istruzioni** si trovano in una sezione, le **variabili globali** inizializzate in un'altra sezione e le **variabili non inizializzate** in un'altra ancora.

Per generare un eseguibile vengono finalizzati due processi: la **risoluzione dei simboli** e la **rilocazione**

Risoluzione dei simboli e rilocazione

Risoluzione dei simboli

I file oggetto definiscono e fanno riferimento a simboli, dove ogni simbolo corrisponde a una **funzione**, a una variabile **globale** o a una variabile **statica** (cioè qualsiasi variabile C dichiarata con l'attributo **static**). Lo scopo della risoluzione dei simboli è quello di associare a ogni riferimento di simbolo esattamente una definizione di simbolo.

Rilocazione

I compilatori e gli assemblatori generano sezioni di codice e di dati **che iniziano all'indirizzo 0**. Il linker ricolloca queste sezioni associando una posizione di memoria a ogni definizione di simbolo e modificando tutti i riferimenti a tali simboli in modo che puntino a questa posizione di memoria.

Quanti tipi di file oggetto esistono?

1. **File oggetto rilocabili**: Contengono codice e dati in forma tale da poter essere combinati con altri file oggetto rilocabili a creare un file oggetto eseguibile
2. **File oggetto eseguibili**: Contengono codice e dati in forma tale da poter esser copiati in memoria centrale ed eseguiti
3. **File oggetto condivisibili (shared)**: tipo speciale di file oggetto che possono essere caricati in memoria e linkati dinamicamente durante il caricamento (librerie dinamiche) o durante l'esecuzione (vedi funzione `dlopen()`)

Executable and Linkable Format (ELF) Rilocabile

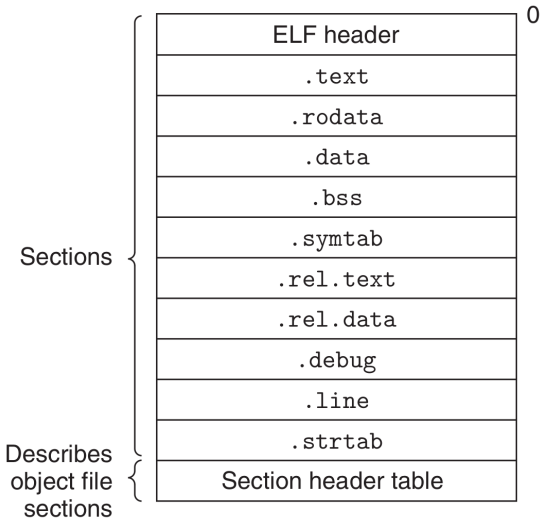

ELF Rilocabile

Definizione

Il formato **ELF (Executable and Linkable Format)** è uno standard per file eseguibili, oggetto, librerie condivise e core dump, ampiamente utilizzato nei sistemi Unix-like, tra cui Linux. A differenza di un ELF eseguibile, un file rilocabile (tipicamente associato ai file oggetto (.o), non ha segmenti (program headers), perché non è ancora pronto per essere caricato in memoria.

Un file ELF rilocabile è organizzato in tre parti principali:

1. **ELF Header:** Contiene metadati sul file (architettura, tipo, offset delle sezioni, ecc.).
2. **Sezioni (Sections)**: Aree che contengono codice, dati, simboli, informazioni di rilocazione, ecc.
3. **Header delle Sezioni (Section Headers):** Una tabella che descrive ogni sezione presente nel file.

ELF Header

L'ELF Header si trova all'inizio del file e definisce:

- **Magic number (0x7F 'E' 'L' 'F')** per identificare il formato (aprite a.out con hexyl!)
- **Classe:** (32/64 bit).
- **Tipo:** Rilocabile/Non Rilocabile.
- **Architettura:** (es. x86, ARM).
- Offset delle sezioni e della section header table.

Sezioni principali di un ELF rilocabile

Un ELF rilocabile (file oggetto) contiene diverse sezioni, tra cui:

- `.text`: Contiene il codice macchina (istruzioni) generato dal compilatore.
- `.data`: Variabili globali inizializzate.
- `.bss`: Variabili globali non inizializzate (occupa spazio solo a runtime).
- `.rodata`: Dati di sola lettura (es. stringhe costanti).
- `.symtab`: (Symbol ¡Table) Tabella dei simboli, che include: funzioni definite (global/extern), Variabili globali, Simboli non risolti (riferimenti esterni).
- `.rel.text` e `.rel.data`: Tabelle di rilocazione che indicano al linker come modificare i riferimenti a simboli esterni o indirizzi assoluti.

Tabella dei simboli

La symbol table (sezione .symtab) è una struttura dati negli ELF che tiene traccia di:

- Funzioni e variabili globali definite nel file oggetto (anche dette nonstatic).
- Simboli esterni (riferimenti a funzioni/variabili definiti altrove, external).
- Simboli locali (funzioni e variabili definite static)

Supponiamo di avere il seguente codice:

```
1 extern int external_var;  // Simbolo esterno (non definito qui)
2 int global_var = 42;      // Simbolo globale definito
3 void foo() {}             // Funzione definita
```

Dopo la compilazione possiamo usare readelf -s prog per ottenere:

```
1 Num:    Value  Size Type    Bind   Vis      Ndx Name
2   0: 00000000     0 NOTYPE  LOCAL  DEFAULT  UND
3   1: 00000000     0 FILE    LOCAL  DEFAULT  ABS example.c
4   2: 00000000     0 SECTION LOCAL  DEFAULT    1 .text
5   3: 00000000    11 FUNC    GLOBAL DEFAULT    1 foo
6   4: 00000000     4 OBJECT  GLOBAL DEFAULT    3 global_var
7   5: 00000000     0 NOTYPE  GLOBAL DEFAULT  UND external_var
```

Executable ELF

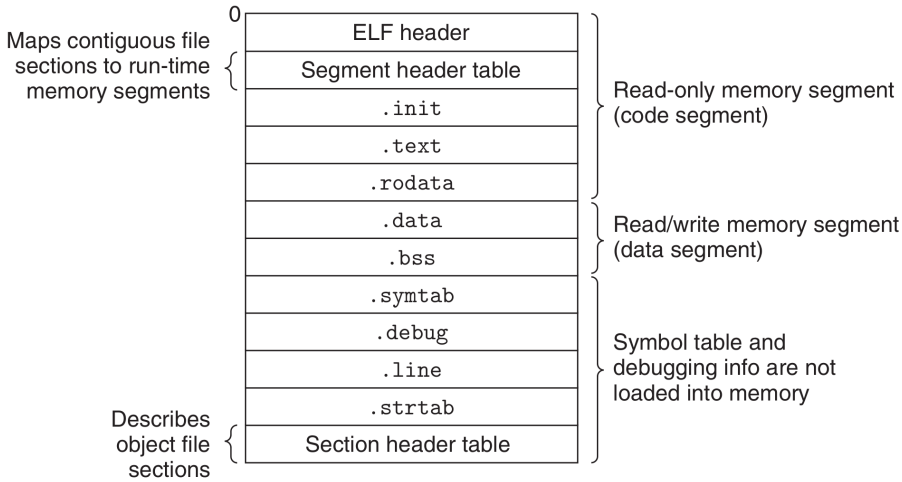

Run-time memory image

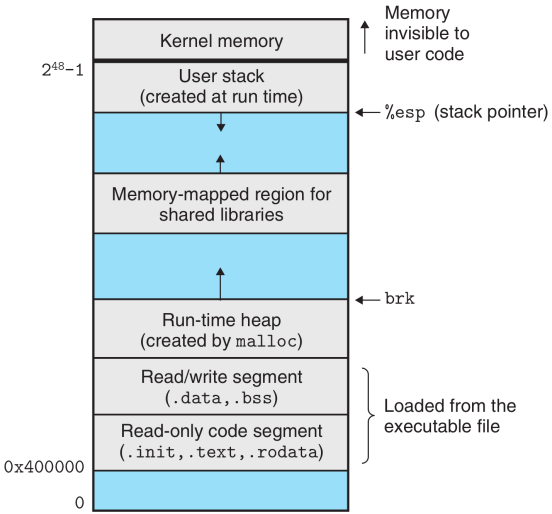

Linker Memory map

La si ottiene con il comando `ld --verbose` ed è diversa per ogni sistema operativo e per ogni architettura. Serve per istruire il linker sugli offset di rilocazione.
Propongo un esempio didattico di mappa della memoria:

```
.text    0x1000    : { *(.text) }     # Codice a 0x1000
.data    0x2000    : { *(.data) }     # Dati a 0x2000
```

Supponiamo ora di avere due file asm da dover assemblare e rilocare. main.asm → main.o

```
; File: main.asm
CALL somma    ; Chiama la funzione "somma"
MOV  AX, x    ; Accede alla variabile "x"
```

math.asm → math.o

```
; File: math.asm
x DB 5        ; Definisce la variabile "x"
somma:        ; Definisce la funzione "somma"
    ADD AX, BX
    RET
```

Risoluzione dei nomi e rilocazione

Dopo la **risoluzione dei nomi** il codice diventa:

```
1 CALL 0x1000; Sostituito "somma" con l'indirizzo 0x1000
2 MOV AX, [0x2000]; Sostituito "x" con l'indirizzo 0x2000
```

Dopo la **rilocazione** (somma di un offset di rilocazione: es. 0x5000) il codice diventa:

```
1 CALL 0x7000       ; Chiama "somma" all'indirizzo 0x7000
2 MOV  AX, [0x6000] ; Accede a "x" all'indirizzo 0x6000
```

Risoluzione dei nomi e rilocazione

`objdump -d main.o`

```
1 main.o:     file format elf64-x86-64
2
3 Disassembly of section .text:
4 0000000000000000 <_start>:
5    0:   e8 00 00 00 00          call   5 <_start+0x5>  # Chiama 'somma
     ' (indirizzo non ancora risolto)
6    5:   8b 05 00 00 00 00       mov    eax, [rip+0x0]  # Accede a 'x'
     (indirizzo non ancora risolto)
```

Risoluzione dei nomi e rilocazione

`objdump -d math.o`

```
1  math.o:     file format elf64-x86-64
2
3  Disassembly of section .text:
4  0000000000000000 <somma>:
5     0:   01 d8                   add    eax, ebx
6     2:   c3                      ret
7
8  Disassembly of section .data:
9  0000000000000000 <x>:
10    0:   05 00 00 00             mov    eax, 0x0  # Valore di 'x' = 5
```

Risoluzione dei nomi e rilocazione

Dopo `ld main.o math.o -o prog` e disassemblando con objdump l'ELF eseguibile prog:

```
1  Disassembly of section .text:
2  0000000000401000 <_start>:
3    401000:   e8 0b 00 00 00        call   401010 <somma>  # Risolto:
       call a 0x401010
4    401005:   8b 05 05 10 00 00     mov    eax, [rip+0x1005] # Risolto: x
         a 0x402000
5
6  0000000000401010 <somma>:
7    401010:   01 d8                 add    eax, ebx
8    401012:   c3                    ret
9
10 Disassembly of section .data:
11 0000000000402000 <x>:
12   402000:   05 00 00 00           mov    eax, 0x0   # x = 5
```

Indirizzo_di_destinazione = Indirizzo_della_prossima_istruzione + Offset_relativo

Recap

Dopo la generazione dell'ELF eseguibile il programma è pronto per il loading e la presa in carico da parte dello scheduler.
Concetti introdotti (fondamentali!!):

1. Compilazione granulare
2. ELF file
3. Linking statico e dinamico
4. Risoluzione dei simboli e rilocazione
5. Tool *nix per l'analisi statica (objdump, readelf, ld, ldd, nm, size, ar)